REPORTE DE ANÁLISIS DE DATOS

Engagement en videos en tendencia de YouTube México

Categorías, horarios de publicación y métricas de interacción

Fuente de datos: MXvideos.csv (videos en tendencia, México)
Periodo en tendencia: 14 de noviembre de 2017 al 14 de junio de 2018
Registros analizados: 40,402 filas (33,513 videos únicos)
Fecha del reporte: Octubre de 2026
Versión: 1.0

1. Resumen ejecutivo

Contexto y objetivo. Este reporte analiza 40,402 registros de videos que aparecieron en la lista de tendencias de YouTube México. El objetivo es entender qué categorías y qué horarios de publicación se asocian con mayor interacción de la audiencia, medida con tres métricas: tasa de actividad, tasa de rechazo y comentarios por cada 1,000 vistas.

Hallazgos principales

- **La interacción típica es aceptable pero muy dispersa.** La tasa de actividad mediana es 3.40%, en el rango "aceptable" (2–5%). Sin embargo, 40.8% de los registros está por debajo de 2% y 41.6% supera 5%.
- **La categoría marca la mayor diferencia.** Consejos y estilo (9.45%), Viajes y eventos (8.31%) y Educación (7.52%) lideran en interacción. Deportes (0.92%) y ONG y activismo (0.45%) están al fondo, aun con muchas vistas.
- **Las dos categorías más grandes interactúan por debajo de la mediana.** Entretenimiento y Gente y blogs son 53.5% de la muestra y tienen tasas medianas de 2.64% y 2.12%.
- **Publicar entre las 12:00 y las 17:59 (hora de la Ciudad de México) se asocia con más interacción.** La mediana es 4.81% en la tarde, contra 2.41% en la noche y 1.25% en la madrugada. El patrón se repite dentro de varias categorías, pero no en todas.
- **La tasa de rechazo casi no discrimina.** En 98.7% de los registros es menor a 1%, por lo que sirve poco para comparar videos en tendencia.
- **Hallazgo metodológico:** la columna de hora está en UTC, no en hora de México. Con la hora local, las franjas horarias cambian de forma importante (sección 3.3).

Recomendaciones

- Programar publicaciones de entretenimiento, música, cine y gente y blogs en la franja de 12:00 a 17:59 h, y probar en las demás categorías con pruebas A/B.
- Si el objetivo es generar conversación, replicar formatos de las categorías líderes (tutoriales, guías, contenido práctico) e incluir llamadas a comentar en deportes y entretenimiento.
- Usar la mediana y no la media como indicador principal, y dejar de usar la tasa de rechazo como KPI único.

2. Introducción

2.1 Antecedentes y problema

Los creadores de contenido y las marcas que publican en YouTube necesitan decidir qué tipo de video producir y cuándo publicarlo. Los videos en tendencia son una referencia útil porque reúnen contenido que ya logró atraer a una audiencia amplia, y permiten comparar cómo interactúa esa audiencia según la categoría y el momento de publicación.

2.2 Objetivos y preguntas de investigación

- ¿Qué nivel de interacción tienen en general los videos en tendencia en México?
- ¿Qué categorías generan más interacción y cuáles generan más rechazo?
- ¿A qué hora conviene publicar para maximizar la interacción?

- ¿Cómo se relacionan entre sí las vistas, los likes, los dislikes y los comentarios?

2.3 Alcance y limitaciones

El análisis cubre únicamente videos que llegaron a tendencias entre noviembre de 2017 y junio de 2018. No describe a todos los videos de YouTube, por lo que los resultados no deben generalizarse a canales o videos que nunca alcanzaron esa lista. Las relaciones que se reportan son asociaciones, no efectos causales.

3. Datos y metodología

3.1 Fuente y descripción de los datos

El archivo original (MXvideos.csv) tiene 40,451 filas y 16 columnas. Cada fila es un video en un día determinado de tendencia, de modo que un mismo video puede aparecer varias veces. Tras la limpieza se conservaron 12 columnas.

Tabla 1. Resumen del conjunto de datos

Concepto	Valor
Filas en el archivo original	40,451
Duplicados exactos eliminados	49
Filas después de la limpieza	40,402
Videos únicos (video_id)	33,513
Fechas distintas de tendencia	205
Videos publicados en 2017 / 2018	9,810 / 30,572
Videos con publicación anterior a 2017	20
Categorías (category_id)	16
Filas con descripción vacía en el original	4,224

3.2 Limpieza y preparación

El script preprocessing.py aplica las siguientes transformaciones:

- **Duplicados:** elimina las filas idénticas (49).
- **Fecha y hora:** convierte publish_time a formato fecha-hora, quita la zona horaria y extrae la hora (hour).
- **Franja horaria:** clasifica la hora en mañana (6–11), tarde (12–17) y noche (resto del día).
- **Nulos:** reemplaza las descripciones vacías por “ninguna” y las etiquetas “[none]” por “ninguno”.
- **Columnas:** conserva solo las 12 columnas útiles para el análisis (identificador, categoría, título, descripción, etiquetas, fecha, hora, franja, vistas, likes, dislikes y comentarios).

3.3 Corrección de la zona horaria

El campo publish_time del archivo original termina en “Z”, es decir, está en UTC. El script elimina la zona horaria sin convertirla, de modo que la columna hour y las franjas horarias reflejan la hora UTC. México

(Ciudad de México) está 5 o 6 horas por detrás de UTC según el horario de verano, así que, por ejemplo, un video marcado a las 2:00 h se publicó en realidad a las 20:00 o 21:00 h de la noche anterior.

Para este reporte se convirtió publish_time a la zona America/Mexico_City y se recalcularon las horas y las franjas: madrugada (0–5 h), mañana (6–11 h), tarde (12–17 h) y noche (18–23 h). Con las franjas originales, 73.7% de los registros caía en "noche", lo que escondía las diferencias reales.

3.4 Métricas calculadas

El script metrics.py define tres métricas por video:

- **Tasa de actividad** = (likes + comentarios) / vistas × 100. Se interpreta como baja (< 2%), aceptable (2–5%) o excelente (> 5%).
- **Tasa de rechazo** = dislikes / vistas × 100. Se interpreta como muy baja (0–1%), moderada (1–3%), alta (3–5%) o crítica (> 5%).
- **Ratio de comentarios** = comentarios / vistas × 1,000. Se interpreta como bajo (0–2), aceptable (3–5), bueno (6–10) o excelente (> 10).

Las tres métricas se calcularon para los 40,402 registros sin valores nulos ni infinitos, ya que ningún video tiene cero vistas.

3.5 Técnicas de análisis

Se utilizó estadística descriptiva (media, mediana, percentiles), tablas de comparación por categoría y franja horaria, correlaciones de Pearson y Spearman y la prueba de Kruskal-Wallis para comparar grupos. Se prefirió la **mediana** a la media porque las distribuciones tienen colas muy largas: las vistas tienen una asimetría de 22.9 y la media (340,175) es seis veces mayor que la mediana (56,793).

4. Análisis exploratorio

4.1 Estadísticos descriptivos

Tabla 2. Estadísticos descriptivos de las variables principales

Variable	Media	Mediana
Vistas	340,175	56,793
Likes	15,727	1,243
Dislikes	744	63
Comentarios	2,016	195
Tasa de actividad (%)	5.55	3.40
Tasa de rechazo (%)	0.18	0.11
Comentarios por 1,000 vistas	7.59	3.51

Nota: el máximo de vistas es 100.9 millones y el percentil 99 es 4.4 millones.

4.2 Distribución de las variables

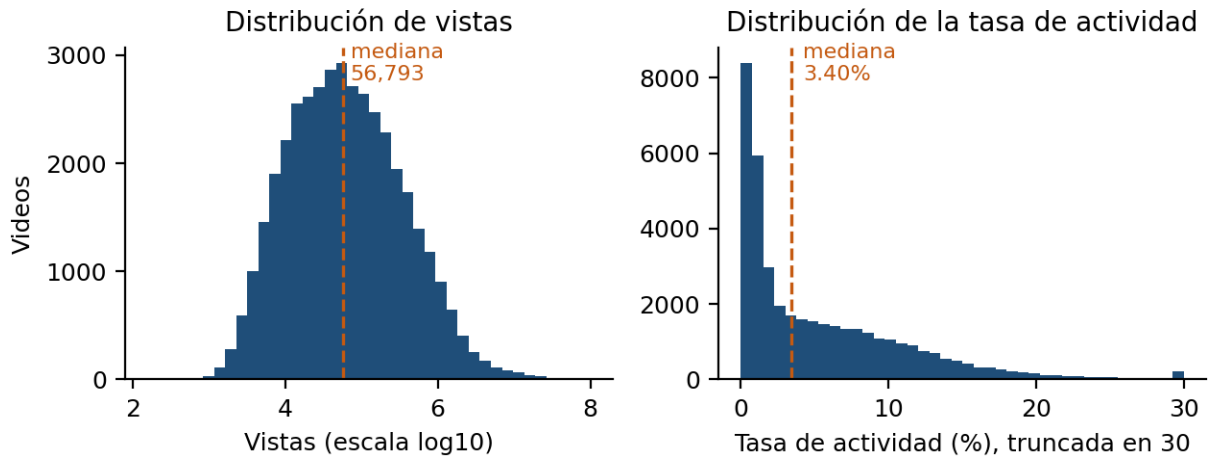


Figura 1. Distribución de las vistas (escala logarítmica) y de la tasa de actividad.

Las vistas se concentran en valores bajos y unos pocos videos muy virales estiran la distribución. La tasa de actividad también tiene una cola larga: la media (5.55%) queda muy por encima de la mediana (3.40%). Por esta razón se usan medianas en el resto del reporte.

4.3 Composición por categoría

Cuatro categorías concentran 71.9% de los registros: Entretenimiento (33.4%), Gente y blogs (20.2%), Deportes (10.0%) y Música (8.3%). La categoría 43 (Shows) solo tiene 3 registros y se excluye de las comparaciones.

4.4 Relaciones entre variables

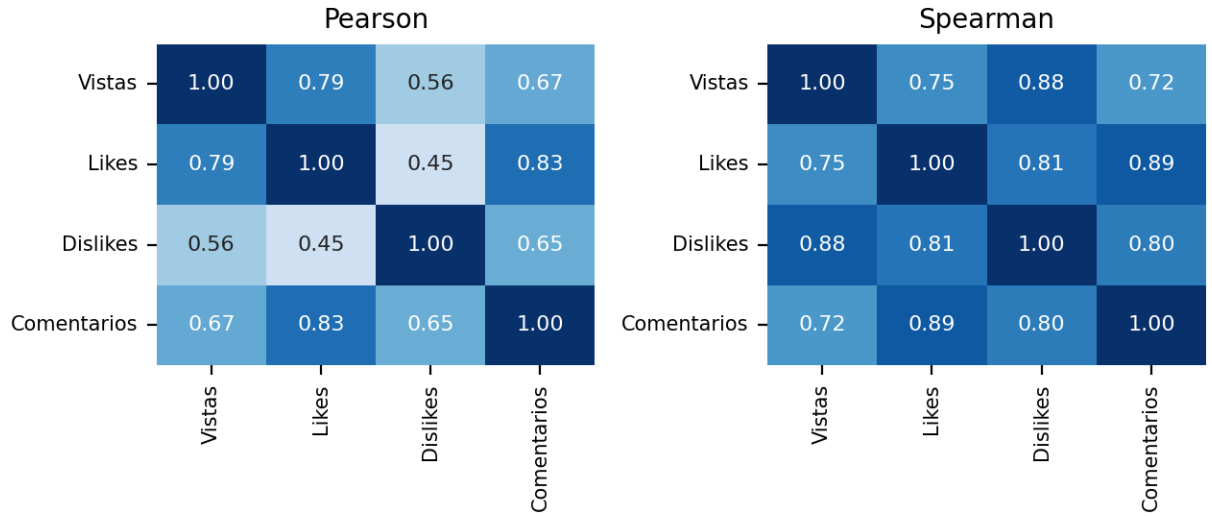


Figura 2. Correlación entre vistas, likes, dislikes y comentarios.

Likes y comentarios son las variables más ligadas (0.83 con Pearson y 0.89 con Spearman). La diferencia entre ambos métodos es mayor para los dislikes: su relación con las vistas pasa de 0.56 (Pearson) a 0.88

(Spearman). Esto indica que, aunque la relación es creciente, los valores extremos distorsionan la correlación lineal, y por eso conviene apoyarse en medidas robustas.

5. Resultados

5.1 ¿Qué nivel de interacción tienen los videos en tendencia?

Tabla 3. Distribución de los registros según las escalas de interpretación

Métrica	Nivel	% de registros
Tasa de actividad	Baja (< 2%)	40.8%
	Aceptable (2–5%)	17.6%
	Excelente (> 5%)	41.6%
Tasa de rechazo	Muy baja (≤ 1%)	98.7%
	Moderada (1–3%)	1.2%
	Alta o crítica (> 3%)	0.2%
Comentarios por 1,000 vistas	Bajo (≤ 2)	36.5%
	Aceptable (> 2 y ≤ 5)	22.6%
	Bueno (> 5 y ≤ 10)	18.4%
	Excelente (> 10)	22.5%

La audiencia de los videos en tendencia está polarizada: hay muchos videos con muy poca interacción y muchos con interacción excelente, y relativamente pocos en el rango intermedio. La tasa de rechazo, en cambio, es bajísima en casi todos los casos.

5.2 ¿Qué categorías generan más interacción?

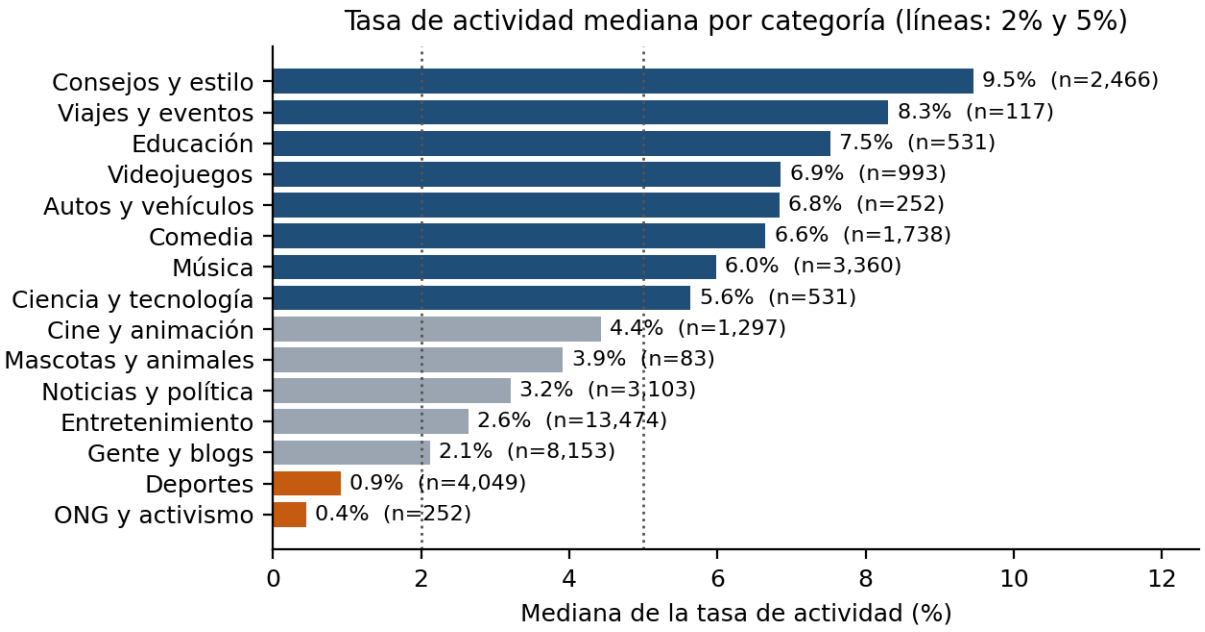


Figura 3. Tasa de actividad mediana por categoría. Naranja: menor a 2%. Gris: entre 2% y 5%. Azul: mayor a 5%.

Tabla 4. Métricas medianas por categoría (ordenadas por tasa de actividad)

Categoría	Videos	Vistas	Actividad (%)	Rechazo (%)	Coment. / 1,000
Consejos y estilo	2,466	28,564	9.45	0.16	8.29
Viajes y eventos	117	72,957	8.31	0.11	7.45
Educación	531	21,417	7.52	0.13	6.86
Videojuegos	993	143,831	6.86	0.14	4.18
Autos y vehículos	252	55,679	6.83	0.14	6.81
Comedia	1,738	141,914	6.65	0.14	4.75
Música	3,360	131,968	5.98	0.11	4.15
Ciencia y tecnología	531	77,436	5.64	0.18	7.02
Cine y animación	1,297	57,099	4.43	0.09	4.03
Mascotas y animales	83	122,662	3.92	0.09	5.57
Noticias y política	3,103	42,908	3.20	0.13	4.55
Entretenimiento	13,474	60,406	2.64	0.12	3.45
Gente y blogs	8,153	29,860	2.12	0.11	2.58
Deportes	4,049	100,727	0.92	0.07	1.66
ONG y activismo	252	47,497	0.45	0.04	1.10

Se excluye la categoría 43 (3 registros). Los nombres de categoría corresponden a la clasificación estándar de YouTube y no vienen en el archivo.

La prueba de Kruskal-Wallis confirma que las diferencias entre categorías son estadísticamente significativas ($p < 0.001$). Algunos patrones destacan:

- **Alta interacción con pocas vistas:** Consejos y estilo y Educación tienen audiencias pequeñas (mediana de 28,564 y 21,417 vistas) pero muy participativas.
- **Muchas vistas, poca conversación:** Deportes tiene una mediana de 100,727 vistas, pero solo 0.92% de actividad y 1.66 comentarios por 1,000 vistas. Es un contenido que se consume sin participar.
- **Videojuegos, Comedia y Música** combinan vistas altas (131,968 a 143,831 de mediana) con interacción alta (5.98% a 6.86%).
- **Rechazo:** las diferencias son pequeñas. Todas las categorías tienen tasas medianas entre 0.04% y 0.18%, por lo que el rechazo no es un diferenciador útil.

5.3 ¿A qué hora conviene publicar?

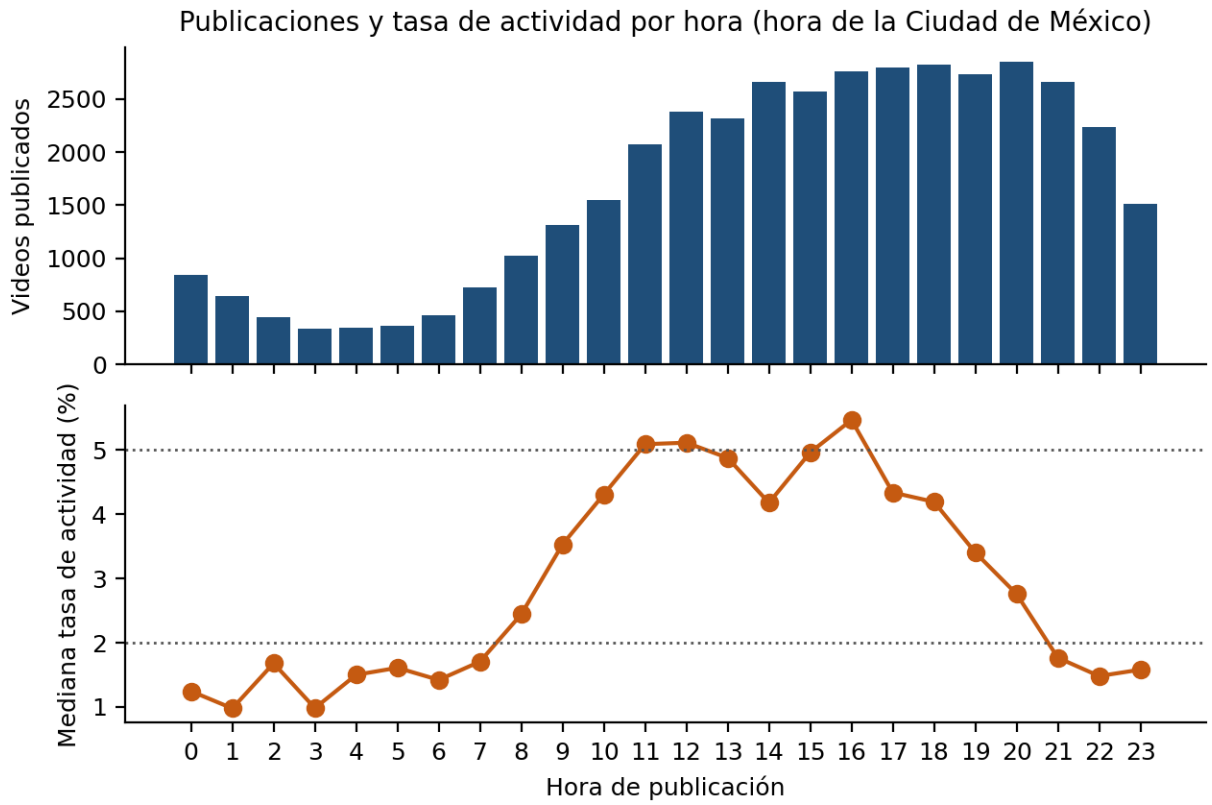


Figura 4. Número de videos publicados y tasa de actividad mediana por hora local.

La publicación se concentra entre las 11:00 y las 22:00 h. La interacción mediana sube a partir de las 8:00 h, alcanza su máximo entre las 11:00 y las 16:00 h (4.2% a 5.5%) y cae por debajo de 2% desde las 21:00 h hasta la madrugada.

Tabla 5. Métricas por franja horaria (hora de la Ciudad de México)

Franja	Videos	Vistas (mediana)	Actividad mediana (%)	Actividad media (%)	Rechazo (%)	Coment. / 1,000
Madrugada (0-5 h)	2,966	78,896	1.25	3.31	0.09	1.48
Mañana (6-11 h)	7,135	67,973	3.52	5.20	0.11	3.39
Tarde (12-17 h)	15,484	63,602	4.81	6.23	0.13	4.78
Noche (18-23 h)	14,817	43,399	2.41	5.45	0.10	3.03

Las diferencias entre franjas son estadísticamente significativas (Kruskal-Wallis, $p < 0.001$). La correlación lineal entre la hora y la tasa de actividad es muy débil (0.06), lo cual es esperable porque la hora es una variable circular y la relación tiene forma de campana, no de línea recta.

5.4 ¿El efecto del horario depende de la categoría?

Parte de la diferencia entre franjas podría deberse a que cada franja tiene una mezcla distinta de categorías. Para revisarlo, la Tabla 6 compara la tasa de actividad mediana por franja dentro de las ocho categorías con más videos.

Tabla 6. Tasa de actividad mediana (%) por categoría y franja horaria

Categoría	Madrugada	Mañana	Tarde	Noche
Entretenimiento	1.05	2.28	4.42	1.93
Gente y blogs	1.09	2.05	3.71	1.66
Deportes	0.71	1.58	0.94	0.86
Música	3.55	5.20	7.21	6.71
Noticias y política	1.69	2.22	3.25	4.52
Consejos y estilo	6.36	9.55	8.72	11.20
Comedia	3.72	4.54	7.25	7.57
Cine y animación	0.62	4.21	6.21	2.65

En Entretenimiento, Gente y blogs, Música y Cine y animación la tarde es la franja con mayor interacción. En Noticias y política, Comedia y Consejos y estilo la noche iguala o supera a la tarde. En Deportes la interacción es baja a cualquier hora. La madrugada es la franja más débil en casi todas las categorías.

6. Discusión

6.1 Interpretación de los resultados

Los resultados sugieren que el tipo de contenido pesa más que el horario. Las categorías de utilidad práctica (consejos, educación, viajes) invitan a comentar y a dar like porque el espectador obtiene algo concreto. En cambio, el contenido de consumo pasivo, como los resúmenes deportivos, acumula vistas sin generar conversación. Esta es una hipótesis razonable, pero los datos no la prueban.

El mejor desempeño en la tarde es consistente con el momento en que la audiencia mexicana tiene tiempo libre y con que los videos llevan más horas publicados al momento de medirse la tendencia. Esta segunda explicación es una limitación: la métrica es una foto del día en que el video fue tendencia, y no se conoce cuántas horas lleva publicado.

6.2 Riesgos, sesgos y limitaciones

- **Sesgo de selección:** solo se observan videos que llegaron a tendencias. Los videos con poca interacción que nunca llegaron a la lista no están en los datos.
- **Videos repetidos:** el 17% de las filas son apariciones adicionales de un mismo video en otros días. Como el archivo limpio ya no incluye trending_date, no es posible distinguirlas. Al deduplicar por video_id (conservando la mayor cantidad de vistas), la tasa de actividad mediana global baja ligeramente de 3.40% a 3.30%, y el orden de las categorías se mantiene en lo esencial (Consejos y estilo sigue primero, y Deportes y ONG y activismo siguen al final).
- **Calificaciones y comentarios desactivados:** 621 registros tienen las calificaciones desactivadas (tasa de actividad mediana de 0.10%) y 431 tienen los comentarios desactivados. Esto reduce artificialmente sus métricas, aunque su peso en la muestra es pequeño (1.5% y 1.1%).
- **Sorteos:** los videos con mayor tasa de actividad entre los que superan 50,000 vistas incluyen varios sorteos (por ejemplo, regalos de iPhone), en los que pedir un comentario o un like es requisito para participar. Estos casos inflan las colas de la distribución.
- **Categorías pequeñas:** Viajes y eventos (117 videos), Mascotas (83) y Autos (252) tienen muestras reducidas y sus resultados son menos estables.

7. Conclusiones y recomendaciones

7.1 Conclusiones principales

- La interacción mediana de los videos en tendencia en México es de 3.40%, con gran variabilidad entre videos.
- La categoría es el factor que más separa a los videos: de 0.45% (ONG y activismo) a 9.45% (Consejos y estilo).
- La franja de 12:00 a 17:59 h tiene la mayor interacción mediana (4.81%), y la madrugada la menor (1.25%).
- La tasa de rechazo es muy baja en prácticamente todos los videos y aporta poca información para comparar.

7.2 Acciones recomendadas

Tabla 7. Acciones priorizadas

Acción	Impacto	Esfuerzo
Publicar en la franja de 12:00 a 17:59 h (hora de México) en entretenimiento, gente y blogs, música y cine	Alto	Bajo
Medir la interacción con la mediana y por categoría, no con el promedio global	Medio	Bajo
Agregar llamadas a comentar en deportes y entretenimiento, donde la conversación es baja	Medio	Bajo
Replicar formatos de tutorial, guía y contenido práctico para elevar la interacción	Alto	Medio
Probar horarios con pruebas A/B controlando la categoría antes de cambiar el calendario	Alto	Medio

7.3 Próximos pasos

- Conservar trending_date en la limpieza para medir cuántos días tarda un video en llegar a tendencia y evitar contar el mismo video varias veces.
- Analizar las etiquetas (tags) y su variación entre 2017 y 2018. La función plot_variacion_tags existe en visualization.py, pero ningún script genera los datos que necesita.
- Agregar un análisis por día de la semana y por canal.
- Construir un modelo (por ejemplo, regresión sobre la mediana de la tasa de actividad) que controle categoría, hora y antigüedad del video a la vez.

Anexos

Anexo A. Archivos y flujo de trabajo

Tabla A1. Archivos del proyecto

Archivo	Función
preprocessing.py	Limpia MXvideos.csv y genera MXvideos_clean.csv
metrics.py	Calcula las tres métricas y genera MXvideos_metrics.csv
visualization.py	Genera las gráficas del análisis
MXvideos.csv	Datos originales (40,451 filas, 16 columnas)
MXvideos_clean.csv	Datos limpios (40,402 filas, 12 columnas)
MXvideos_metrics.csv	Datos limpios más las tres métricas (15 columnas)

Anexo B. Observaciones técnicas sobre el código

Durante la revisión se detectaron puntos que conviene corregir para que el análisis sea reproducible y más preciso:

- **Zona horaria:** convertir publish_time a America/Mexico_City antes de extraer la hora (por ejemplo, con tz_convert), en lugar de quitar la zona con tz_localize(None).
- **Nombre de columna:** en metrics.py la función promedio_ttr_franja_horaria usa “franaja_horaria”, que no existe; debe ser “franja_horaria”.
- **Codificación de texto:** los títulos aparecen con caracteres dañados (por ejemplo, “CapÃtulo”) y en MXvideos_metrics.csv el daño se duplica, incluso en la columna franja_horaria (“maÃ±ana”). metrics.py lee con latin-1 un archivo que preprocessing.py guardó en UTF-8. Usar UTF-8 al leer y escribir.
- **División entre cero:** tasa_rechazo y ratio_comentarios no aplican replace(0, np.nan) a las vistas como sí lo hace tasa_actividad. No afecta a estos datos (no hay vistas en cero), pero conviene homologar.
- **Estadísticos:** las gráficas de barras con seaborn muestran la media con intervalo de confianza. Con distribuciones tan asimétricas es preferible graficar la mediana.
- **Franja “noche”:** agrupa todas las horas fuera de 6–17, es decir, tarde-noche y madrugada juntas. Conviene separar la madrugada.
- **Duplicados:** drop_duplicates elimina solo filas idénticas. Los videos repetidos en otros días de tendencia se conservan.

Anexo C. Nombres de categoría

El archivo solo incluye el identificador numérico (category_id). Los nombres usados en este reporte corresponden a la clasificación estándar de YouTube: 1 Cine y animación, 2 Autos y vehículos, 10 Música, 15 Mascotas y animales, 17 Deportes, 19 Viajes y eventos, 20 Videojuegos, 22 Gente y blogs, 23 Comedia, 24 Entretenimiento, 25 Noticias y política, 26 Consejos y estilo, 27 Educación, 28 Ciencia y tecnología, 29 ONG y activismo y 43 Shows.